FUCAPE
BUSINESS SCHOOL

Avaliação em Recuperação de Informação

PLN e Sistemas de Recuperação de Informação

Prof. Dr. Wagner Perin
FUCAPE Business School

Avaliação de Sistemas de Recuperação de Informação

Da Teoria Offline aos Benchmarks em Escala e Experimentação Online

Disciplina: PLN e Sistemas de Recuperação de Informação
Programa: Ciência de Dados & IA Aplicada a Negócios
Docente: Prof. Dr. Wagner Perin
Carga Horária: 4 h/a (200 min) | **Unidade 4:** Avaliação em RI

INSIGHT EXECUTIVO

Princípio de Negócio em Recuperação de Informação:
"Um mecanismo de busca veloz que entrega respostas inúteis apenas queima a paciência do cliente em milissegundos."



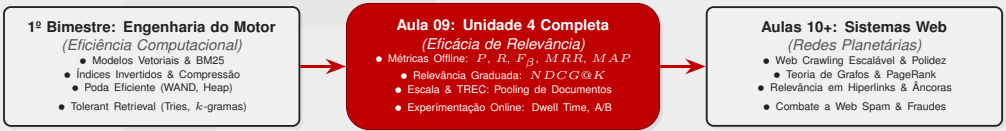
- **Abertura do 2º Bimestre:** Transição do foco em custo e latência de máquina para eficácia, relevância percebida e geração de receita.
- **Escopo Analítico:** Métricas Set-based, Rankings de Top-K, Relevância Graduada ($NDCG$), Benchmarks TREC e Sinais Online.

Transição Pedagógica — Da Eficiência à Eficácia

Do Motor Algorítmico à Satisfação Humana e Geração de Receita

REFLEXÃO ANALÍTICA & DILEMA DE NEGÓCIO

Roteiro de Continuidade: O 1º Bimestre construiu o motor; o 2º Bimestre garante que ele responda à real necessidade humana e gere valor financeiro ao negócio.



INSIGHT EXECUTIVO

A Virada Estratégica da Disciplina:
Substituímos a pergunta técnica de máquina (*"Quão rápido e barato o algoritmo executa?"*) pela pergunta estratégica de produto e dados (*"Quão relevante, confiável e satisfatória é a resposta entregue ao usuário?"*).

A Dor de Negócio — A Armadilha do CTR no MegaVarejo S.A.

O Conflito Crítico entre Métricas de Vaidade e Valor Real ao Cliente

REFLEXÃO ANALÍTICA & DILEMA DE NEGÓCIO

Problema Investigado: No MegaVarejo S.A., a equipe de busca otimizou exclusivamente cliques (CTR). O CTR saltou 88%, mas o faturamento caiu 19,5%.



O Relatório Executivo da Crise:

- **A Ilusão Inicial:** O CTR médio subiu de $14,2\%$ **para** $26,8\%$ e a latência permaneceu excelente em 11 **ms**.
- **O Impacto Destrutivo no Negócio:**
  1. **Queda de $19,5\%$ no GMV:** Abandono massivo no checkout;
  2. **Epidemia de *Pogo-Sticking* (+320%):** O cliente clicava no item apelativo, via que era irrelevante e voltava;
  3. **Avaliação do App Despencou ($4,6 \rightarrow 2,1$):** *"Busquei notebook Dell i7 e recebi capas plásticas de R$ 15!"*.
- **Lição de Governança:** Métricas de vaidade capturam *clickbait*, ignorando a **eficácia de relevância**.

Eficiência Computacional vs. Eficácia de Recuperação

Matriz Comparativa entre Engenharia de Sistemas e Ciência de Dados

Dimensão	Eficiência Computacional (1º Bimestre)	Eficácia de Recuperação (2º Bimestre)
Foco Central	Uso otimizado de hardware, memória e latência	Qualidade, utilidade e ordenação das respostas
Métricas	Latência ($p95, p99$), Throughput (QPS), RAM	Precisão, Revocação, F_β, MRR, MAP, $NDCG@K$
Pergunta-Chave	*"Quão rápido e barato o algoritmo roda?"*	*"Quão satisfeito o usuário ficou com a busca?"*
Impacto da Falha	Sobrecarga de servidores, custos de nuvem	Abandono do cliente, frustração, perda direta de GMV
Método de Medição	Testes de estresse de carga e concorrência	Paradigma Cranfield, anotação humana e Testes A/B

INSIGHT EXECUTIVO

A Regra de Ouro em Ciência de Dados para Negócios:
A **Eficiência** é condição *necessária* (respostas lentas expulsam o usuário), mas apenas a **Eficácia** é condição *suficiente* para gerar retenção, conversão e valor financeiro sustentável.

O Paradigma de Cranfield — O Alicerce da Avaliação Offline

Padronização Científica e Reprodutibilidade Laboratorial (Cleverdon, 1960s)

A Tríade Canônica: $\langle \mathcal{D},\ \mathcal{Q},\ \mathcal{R} \rangle$

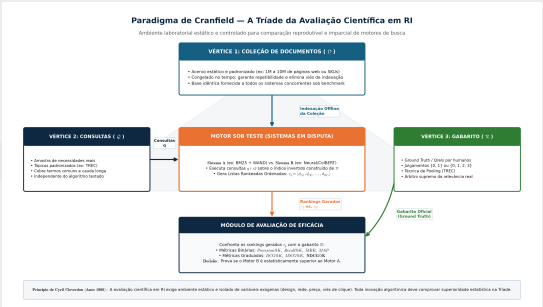
1. **Coleção de Documentos ($\mathcal{D}$):** Acervo representativo e **congelado** sobre o qual todos os algoritmos concorrentes operam sob as mesmas condições exatas.
2. **Conjunto de Consultas ($\mathcal{Q}$):** Amostra equilibrada de necessidades reais de informação formuladas pelos usuários (consultas curtas, ambíguas e de cauda longa).
3. **Gabarito de Relevância ($\mathcal{R}$):** Veredito de referência (*Ground Truth*) emitido por especialistas humanos treinados, indicando a relevância de cada par (q, d).

INSIGHT EXECUTIVO

Por que Avaliar em Laboratório (Offline)?
Permite comparar dezenas de variantes algorítmicas nas **mesmas condições controladas**, sem expor clientes reais a modelos instáveis, sem colocar o faturamento em risco e com **reprodutibilidade científica auditável**.

O Paradigma de Cranfield — Arquitetura de Laboratório

Isolamento de Variáveis e Comparabilidade Rigorosa entre Motores



INSIGHT EXECUTIVO

Síntese Arquitetural:
O congelamento rigoroso da coleção documental ($\mathcal{D}$) e do gabarito humano ($\mathcal{R}$) assegura a validade causal do experimento. Se o Algoritmo B obtiver métricas superiores ao Algoritmo A, a melhoria decorre exclusivamente da inteligência da sua função de ranqueamento.

Camada 1 — A Tabela de Contingência 2×2 em RI

Formalização dos Quadrantes entre Recuperação do Sistema e Relevância Real

REFLEXÃO ANALÍTICA & DILEMA DE NEGÓCIO

Formalização Teórica: Para uma consulta q, dividimos a coleção de N documentos entre o que o motor recuperou (Rec) e o que é verdadeiramente relevante (Rel).

Classificação do Algoritmo	Documento Relevante ($\in$ Rel)	Documento Não-Relevante ($\notin$ Rel)	Total do Sistema
Recuperado ($\in$ Rec)	**Verdadeiro Positivo (TP)**	**Falso Positivo (FP)**	$\lvert\text{Rec}\rvert = TP + FP$
Não Recuperado ($\notin$ Rec)	**Falso Negativo (FN)**	**Verdadeiro Negativo (TN)**	$N - \lvert\text{Rec}\rvert = FN + TN$
Total no Acervo	$\lvert\text{Rel}\rvert = TP + FN$	$N - \lvert\text{Rel}\rvert = FP + TN$	**População Total:** N

TP (Sucessos)
Úteis resgatados com êxito pelo sistema.

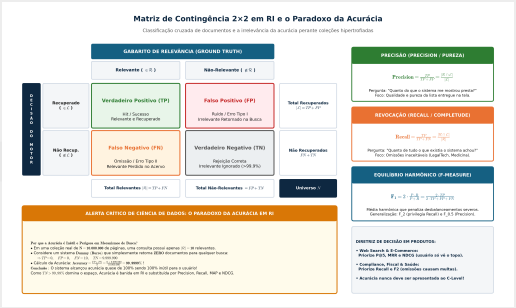
FP (Ruído)
Lixo ou irrelevantes entregues ao usuário.

FN (Omissões)
Vitais perdidos e não recuperados na busca.

TN (Maioria)
Oceano irrelevante corretamente ignorado.

A Tabela de Contingência 2×2 — Mapeamento Visual

A Hipertrofia do Quadrante dos Verdadeiros Negativos (TN)



INSIGHT EXECUTIVO

Diagnóstico Estrutural de Dados:
Em bases industriais de milhões de páginas, o quadrante dos Verdadeiros Negativos (TN) é hipertrofiado ($> 99,99\%$). Essa assimetria extrema torna qualquer métrica que inclua TN no numerador (como a Acurácia simples) estatisticamente falaciosa e inútil para RI.

Precisão vs. Revocação — Definições e Intuição de Negócio

Pureza da Resposta versus Completude do Resgate no Acervo

INSIGHT EXECUTIVO

1. Precisão ($Precision$ — Pureza)

$$P = \frac{|\text{Rel} \cap \text{Rec}|}{|\text{Rec}|} = \frac{TP}{TP + FP}$$

Pergunta do Usuário:
"Quanto daquilo que o motor me mostrou é útil?"
Foco de Negócio:
Reduzir o lixo nas primeiras posições da tela (mandatório em Web Search, E-commerce e Mobile).

INSIGHT EXECUTIVO

2. Revocação ($Recall$ — Completude)

$$R = \frac{|\text{Rel} \cap \text{Rec}|}{|\text{Rel}|} = \frac{TP}{TP + FN}$$

Pergunta do Usuário:
"Quanto de tudo o que existia o motor achou?"
Foco de Negócio:
Não deixar nenhum documento essencial escapar (mandatório em LegalTech, Compliance e Saúde).

REFLEXÃO ANALÍTICA & DILEMA DE NEGÓCIO

O Trade-off Inevitável:
Retornar mais itens aumenta o $Recall$, mas arrasta ruído ($Precision \downarrow$); filtrar rigorosamente eleva a $Precision$, mas corre o risco de omitir itens cruciais ($Recall \downarrow$).

O Paradoxo da Acurácia em RI — Por que ela mente?

O Colapso da Métrica Clássica perante o Desbalanceamento Extremo de Classes

REFLEXÃO ANALÍTICA & DILEMA DE NEGÓCIO

Alerta de Governança: Em comitês técnicos de Ciência de Dados, nunca aceite a métrica de Acurácia para validar um mecanismo de busca corporativo!

Demonstração Numérica do Colapso da Acurácia:

- Acervo com $N = 10.000.000$ de produtos e uma consulta com apenas 10 itens relevantes ($|\text{Rel}| = 10$).
- Motor quebrado que retorna **zero resultados** ($\text{Rec} = \emptyset$):

$$TP = 0 \quad | \quad FP = 0 \quad | \quad FN = 10 \quad | \quad TN = 9.999.990$$

$$\text{Acurácia} = \frac{TP + TN}{N} = \frac{0 + 9.999.990}{10.000.000} = \mathbf{99,9999\%}!$$

INSIGHT EXECUTIVO

O Diagnóstico Técnico:
O sistema ostenta $99,9999\%$ de acurácia, mas possui 0% **de utilidade real** para o usuário final ($Precision = 0$, $Recall = 0$).

INSIGHT EXECUTIVO

A Causa Estrutural:
O oceano de irrelevantes (TN) camufla por completo a incompetência algorítmica de localizar os documentos vitais (TP).

A Média Harmônica e a Medida F_β (F_1, F_2, $F_{0.5}$)

Ponderação Paramétrica entre Pureza e Completude (van Rijsbergen, 1979)

REFLEXÃO ANALÍTICA & DILEMA DE NEGÓCIO

Por que a média harmônica? Se um motor tem $P = 1,0$ e $R = 0,02$, a média aritmética é $0,51$ (enganosa). A média harmônica penaliza severamente o colapso de qualquer dimensão!

$$F_\beta = \frac{(1+\beta^2) \cdot P \cdot R}{\beta^2 \cdot P + R} = \frac{(1+\beta^2)}{\frac{\beta^2}{R} + \frac{1}{P}}$$

- F_1**-Score (**$\beta = 1$ **— Equilíbrio Simétrico):**

$$F_1 = \frac{2 \cdot P \cdot R}{P + R} \quad \longrightarrow \quad \text{No exemplo anterior: } F_1 = \frac{2 \cdot 1,0 \cdot 0,02}{1,0 + 0,02} = \mathbf{0,0392} \text{ (Reflete o colapso!)}$$

- F_2**-Score (**$\beta = 2$ **— Prioridade para Revocação):** Confere $2\times$ mais peso ao $Recall$. Mandatório em **LegalTech** (*due diligence*) e **Diagnósticos Clínicos**.
- $F_{0.5}$**-Score (**$\beta = 0.5$ **— Prioridade para Precisão):** Confere $2\times$ mais peso à $Precision$. Ideal para **Buscadores Web** e **E-commerce**.

Camada 2 — O Limite dos Conjuntos: Por que a Ordem Importa?

A Insuficiência das Métricas Set-based para Avaliar a Experiência do Usuário

INSIGHT EXECUTIVO

Motor A: Sucesso no 1º Clique

Posição 1:	Doc 1 (Relevante)	ACERTO
Posição 2:	Doc 2 (Relevante)	ACERTO
Posição 3:	Doc 3 (Relevante)	ACERTO
Posição 4:	Doc 4 (Irrelevante)	ERRO
Posição 5:	Doc 5 (Irrelevante)	ERRO

INSIGHT EXECUTIVO

Motor B: Frustração e Fadiga

Posição 1:	Doc 4 (Irrelevante)	ERRO
Posição 2:	Doc 5 (Irrelevante)	ERRO
Posição 3:	Doc 1 (Relevante)	ACERTO
Posição 4:	Doc 2 (Relevante)	ACERTO
Posição 5:	Doc 3 (Relevante)	ACERTO

INSIGHT EXECUTIVO

Diagnóstico das Métricas Clássicas Baseadas em Conjunto:

- Motor A: $TP = 3, FP = 2 \implies \mathbf{Precision = 0,60, Recall = 1,00, F_1 = 0,75}$
- Motor B: $TP = 3, FP = 2 \implies \mathbf{Precision = 0,60, Recall = 1,00, F_1 = 0,75}$

A Miopia dos Conjuntos: Pelo F_1, ambos são idênticos! Mas no Motor B o usuário sofre duas rejeições antes do primeiro clique. **A ordem na lista determina a experiência humana!**

Métricas de Top-K: $Precision@K$ e $Recall@K$

Adaptando a Avaliação à Dobra de Tela e à Janela de Atenção Humana

INSIGHT EXECUTIVO

1. Precision@K ($P@K$)

$$P@K = \frac{\text{Itens Relevantes no Top-}K}{K}$$

Exemplo Comparativo ($K = 3$):
- Motor A: 3 acertos em 3 posições:

$$P@3 = \frac{3}{3} = \mathbf{1,00}$$

- Motor B: 0 acertos em 3 posições:

$$P@3 = \frac{0}{3} = \mathbf{0,00}$$

O $P@K$ captura com precisão cirúrgica a falha inicial de ranqueamento!

INSIGHT EXECUTIVO

2. Recall@K e R-Precision

$$R@K = \frac{\text{Itens Relevantes no Top-}K}{|\text{Rel}|}$$

R-Precision (Corte Dinâmico):
Fixa $K = |\text{Rel}|$ para cada consulta individual.

- Se a consulta possui 4 itens úteis na base, avalia-se estritamente $P@4$.
- Elimina distorções causadas por buscas com volumes desiguais de itens úteis.

Mean Reciprocal Rank (MRR) — A Métrica do Primeiro Acerto

Penalização Hiperbólica da Posição para Buscas de Item Conhecido e Voz

$$RR(q) = \frac{1}{\text{rank}_1(q)} \quad \Longrightarrow \quad MRR = \frac{1}{|\mathcal{Q}|} \sum_{q \in \mathcal{Q}} \frac{1}{\text{rank}_1(q)}$$

Exemplo Prático sobre Consultas Corporativas:

- **Consulta 1 (`"manual dell latitude 5420"`):** 1º acerto na posição $1 \implies RR_1 = 1/1 = \mathbf{1,00}$
- **Consulta 2 (`"termo de garantia iphone 15"`):** 1º acerto na posição $2 \implies RR_2 = 1/2 = \mathbf{0,50}$
- **Consulta 3 (`"cnpj matriz petrobras sa"`):** 1º acerto na posição $4 \implies RR_3 = 1/4 = \mathbf{0,25}$

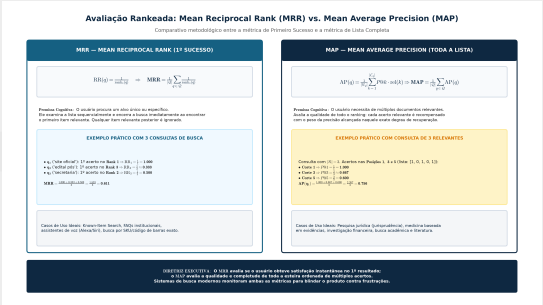
$$MRR = \frac{1,00 + 0,50 + 0,25}{3} = \frac{1,75}{3} \approx \mathbf{0,5833}$$

INSIGHT EXECUTIVO

Intuição de Negócio:
Se o assistente de voz acerta de primeira, nota 1,0; na 2ª posição, a nota cai pela metade; na 4ª posição, cai 75%. Após o primeiro acerto, itens subsequentes não afetam o cálculo.

Comparativo Conceitual: MRR versus MAP

Primeiro Acerto Pontual versus Dispersão Global de Itens Relevantes



INSIGHT EXECUTIVO

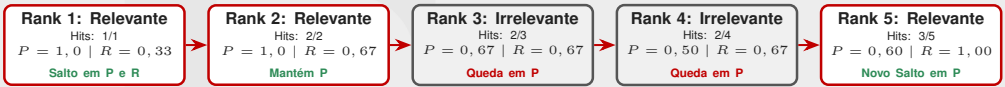
Síntese Arquitetural:
O MRR encerra sua avaliação assim que o primeiro documento útil é alcançado (ideal para interfaces de voz ou busca por SKU único), enquanto o MAP avalia a integral da distribuição de **todos** os documentos relevantes pela lista.

A Curva de Precisão-Revocação — O Comportamento Dente-de-Serra

Dinâmica de Inspeção de Documentos Passo a Passo ($K = 1, 2, 3, \ldots, N$)

REFLEXÃO ANALÍTICA & DILEMA DE NEGÓCIO

Inspeção Dinâmica: O que acontece com a Precisão e a Revocação à medida que o usuário vai rolando a tela para baixo e examinando os resultados sequencialmente?



1. **Revocação Monótona Crescente:** A revocação nunca diminui; a cada acerto, dá um salto de $\frac{1}{|\text{Rel}|}$.
2. **Precisão em Dente-de-Serra (*Sawtooth*):** Sobe a cada acerto e cai a cada documento irrelevante encontrado.
3. **Dilema Metodológico:** Consultas heterogêneas atingem níveis de revocação em posições totalmente díspares.

Interpolação TREC em 11 Pontos — Suavização da Curva

Padronização em Níveis Fixos de Revocação para Comparação de Sistemas

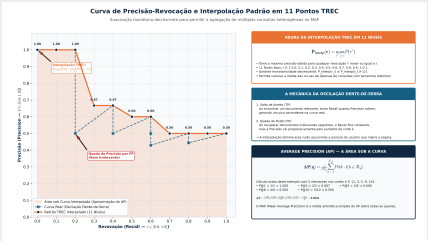
REFLEXÃO ANALÍTICA & DILEMA DE NEGÓCIO

Padronização TREC: Para permitir a média sobre centenas de consultas, normalizamos a curva em 11 patamares fixos: $r \in \{0.0, 0.1, 0.2, \ldots, 1.0\}$.

Regra da Máxima Precisão à Direita:

$$P_{\text{interp}}(r) = \max_{r' \geq r} P(r')$$

- **Intuição Operacional:** *"Para um nível pretendido de revocação* r*, qual foi a maior precisão alcançada dali para a frente?"*
- **Propriedades Analíticas:**
  1. Converte o dente-de-serra em função **estritamente monótona decrescente**;
  2. Elimina penalidades causadas por ruídos locais;
  3. Permite calcular a **curva média do sistema** no TREC.



Mean Average Precision (MAP) — A Área sob a Curva Binária

O Resumo Escalar da Qualidade Global de Ranqueamento em Múltiplas Consultas

REFLEXÃO ANALÍTICA & DILEMA DE NEGÓCIO

O Padrão Histórico da Academia: Como resumir toda a curva de Precisão-Revocação de uma consulta em um único número representativo e comparável?

INSIGHT EXECUTIVO

1. Average Precision (AP de q)

$$AP(q) = \frac{1}{|\text{Rel}_q|} \sum_{k=1}^{|\text{Rec}_q|} P@k \cdot \mathbb{I}(k \in \text{Rel}_q)$$

Mecânica de Cálculo:

- $\mathbb{I}(k \in \text{Rel}_q) = 1$ apenas nos ranks relevantes.
- Se o motor omitir itens úteis no Top-K, o denominador fixo $|\text{Rel}_q|$ penaliza a nota severamente!

INSIGHT EXECUTIVO

2. Mean Average Precision (MAP)

$$MAP = \frac{1}{|\mathcal{Q}|} \sum_{q \in \mathcal{Q}} AP(q)$$

Interpretação Geométrica:

- O MAP aproxima a **área sob a curva de precisão-revocação**.
- Recompensa fortemente algoritmos que concentram todos os documentos relevantes no topo da lista.

Rastreamento Tabular do MAP — Demonstração Passo a Passo

Cálculo Detalhado em Consultas Heterogêneas (Q_1 e Q_2)

Consulta Q_1 ($|\text{Rel}_{Q_1}| = 3$ documentos relevantes na base):

Rank	Doc	Relevante?	Acertos	$P@k$ no Acerto
1	Doc A	Sim	1	$P@1 = 1/1 = \mathbf{1,0000}$
2	Doc B	Não	1	— *(ignorado)*
3	Doc C	Sim	2	$P@3 = 2/3 \approx \mathbf{0,6667}$
4	Doc D	Não	2	— *(ignorado)*
5	Doc E	Sim	3	$P@5 = 3/5 = \mathbf{0,6000}$

$$AP(Q_1) = \frac{1,000 + 0,667 + 0,600}{3} = \mathbf{0,7556}$$

Consulta Q_2 ($|\text{Rel}_{Q_2}| = 4$ relevantes no acervo):

- Acertos nas posições 2, 4, 6 e omitiu o 4º item:

$$P@2 = \frac{1}{2} = 0,50 \quad | \quad P@4 = \frac{2}{4} = 0,50$$

$$P@6 = \frac{3}{6} = 0,50 \quad | \quad \text{Item 4} = 0,00$$

$$AP(Q_2) = \frac{0,50 + 0,50 + 0,50 + 0}{4} = \mathbf{0,3750}$$

INSIGHT EXECUTIVO

Cálculo Global do MAP da Coleção:

$$MAP = \frac{0,7556 + 0,3750}{2} = \mathbf{0,5653}$$

Camada 3 — Relevância Graduada e a Falência do Binário

A Complexidade do E-commerce: Por que a Visão Binária Destrói o Faturamento?

REFLEXÃO ANALÍTICA & DILEMA DE NEGÓCIO

A Ruptura do Modelo Clássico: No mundo real dos negócios, a relevância quase nunca é simplesmente 0 ou 1. Tratar tudo como binário destrói a margem e a conversão!

Cenário Real: Busca por `"iPhone 15 Pro Max 256GB Titânio"`**:**

- **Nota 3 — Relevante Perfeito:** O aparelho exato solicitado, cor certa e em estoque imediato.
- **Nota 2 — Relevante Excelente:** iPhone 15 Pro (128GB) ou iPhone 15 Plus (mesma família de alta conversão).
- **Nota 1 — Relevante Marginal:** Capa protetora de silicone ou cabo USB-C (acessório de ticket baixo).
- **Nota 0 — Totalmente Irrelevante:** Fogão a gás de 4 bocas ou calça jeans feminina.

INSIGHT EXECUTIVO

Por que o MAP e o $Precision@K$ Falham Catastroficamente Aqui?
Se considerarmos notas $\{1, 2, 3\}$ como "relevantes", o motor que exibe capas de R$ 15 no topo pontuará com nota máxima, idêntico ao motor que traz o smartphone de R$ 7.000!
$\Longrightarrow$ **A Solução Definitiva:** Ganho Cumulativo Descontado Normalizado ($NDCG@K$) (Järvelin & Kekäläinen, 2002).

Construção do $NDCG@K$ — CG e Desconto Logarítmico (DCG)

Modelagem da Recompensa Exponencial e da Fadiga Visual Humana

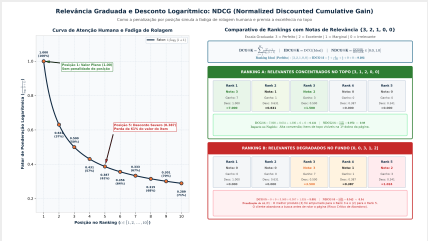
1. Cumulative Gain ($CG@K$):

$$CG@K = \sum_{i=1}^{K} r_i \quad \text{(Falha: ignora a posição!)}$$

2. Discounted Cumulative Gain ($DCG@K$):

$$DCG@K = \sum_{i=1}^{K} \frac{2^{r_i} - 1}{\log_2(i+1)}$$

- **Numerador Exponencial ($2^{r_i} - 1$):** Recompensa brutalmente os itens perfeitos ($r = 3 \implies 7; r = 1 \implies 1$).
- **Denominador Logarítmico ($\log_2(i+1)$):**
  - Posição 1: $\log_2(2) = 1,00$ (sem desconto);
  - Posição 2: $\log_2(3) \approx 1,58$ (desconto de 37%);
  - Posição 5: $\log_2(6) \approx 2,58$ (desconto de 61%).



Ideal DCG ($IDCG$) e a Métrica Definitiva: $NDCG@K$

Normalização pelo Ótimo Teórico e Interpretação Executiva

INSIGHT EXECUTIVO

1. Ranking Ideal ($IDCG@K$)

$$IDCG@K = \sum_{i=1}^{K} \frac{2^{r_{(i)}^{\text{ideal}}} - 1}{\log_2(i+1)}$$

Ordena as notas de relevância dos documentos conhecidos em **ordem estritamente decrescente**. Representa a melhor ordenação humanamente viável para aquela busca.

INSIGHT EXECUTIVO

2. Normalização ($NDCG@K$)

$$NDCG@K = \frac{DCG@K}{IDCG@K} \quad \in [0.0,\ 1.0]$$

Razão direta entre o ganho obtido pelo motor e a perfeição matemática ideal. Permite calcular médias harmônicas entre milhares de consultas díspares.

INSIGHT EXECUTIVO

Interpretação Executiva em Comitês de Negócio:

- $NDCG@K = 1,00$**:** O algoritmo entregou o melhor ordenamento humanamente e teoricamente viável.
- $NDCG@K = 0,85$**:** O motor capturou 85% do potencial máximo de relevância percebida pelo cliente.

Duelo Algorítmico no MegaVarejo — Rastreamento do $NDCG@5$

Comprovação Numérica da Superioridade do Motor A sobre o Motor B

REFLEXÃO ANALÍTICA & DILEMA DE NEGÓCIO

Gabarito: $\{3, 2, 0, 1, 0, 3\}$ | *Ideal:* $[3, 3, 2, 1, 0]$ | *Motor A:* $[3, 2, 0, 1, 0]$ | *Motor B:* $[0, 1, 3, 2, 0]$

Rank (i)	$\log_2(i+1)$	Ganho A	Parcela A	Ganho B	Parcela B	Ganho Ideal	Parcela Ideal
1	$1,0000$	$2^3 - 1 = 7$	$7,0000$	$2^0 - 1 = 0$	$0,0000$	$2^3 - 1 = 7$	$7,0000$
2	$1,5850$	$2^2 - 1 = 3$	$1,8928$	$2^1 - 1 = 1$	$0,6309$	$2^3 - 1 = 7$	$4,4165$
3	$2,0000$	$2^0 - 1 = 0$	$0,0000$	$2^3 - 1 = 7$	$3,5000$	$2^2 - 1 = 3$	$1,5000$
4	$2,3219$	$2^1 - 1 = 1$	$0,4307$	$2^2 - 1 = 3$	$1,2920$	$2^1 - 1 = 1$	$0,4307$
5	$2,5850$	$2^0 - 1 = 0$	$0,0000$	$2^0 - 1 = 0$	$0,0000$	$2^0 - 1 = 0$	$0,0000$
Soma	—	—	$DCG_A = 9,3235$	—	$DCG_B = 5,4229$	—	$IDCG = 13,3472$

INSIGHT EXECUTIVO

Veredito Executivo Incontestável:

$$NDCG@5(\text{Motor A}) = \frac{9,3235}{13,3472} = \mathbf{0,6985} \quad \text{versus} \quad NDCG@5(\text{Motor B}) = \frac{5,4229}{13,3472} = \mathbf{0,4063}$$

O Motor A é $71,9\%$ **superior** ao Motor B porque converteu as posições mais nobres da tela em vendas!

Benchmarks em Grande Escala — O Desafio TREC e o *Pooling*

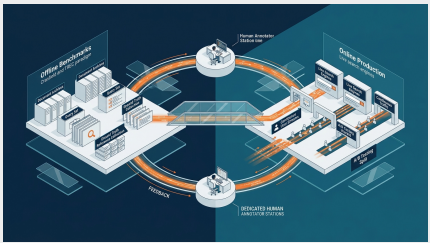
Como Avaliar Coleções de Centenas de Milhões de Documentos com Custo Viável

REFLEXÃO ANALÍTICA & DILEMA DE NEGÓCIO

O Dilema da Escala: Se a coleção possui 100 milhões de páginas e avaliamos 50 buscas, precisaríamos de 5 bilhões de julgamentos humanos. Isso é inviável!

A Solução Genial do TREC (NIST): *Pooling*

1. **Submissão Multi-Sistemas:** Dezenas de motores concorrentes submetem seu Top-K (ex.: $K = 100$).
2. **Formação da Piscina (*Pool*):** Reúne-se a união de todos os Top-100, eliminando duplicatas.
3. **Julgamento Focado:** Auditores avaliam **estritamente os documentos da piscina**.
4. **Hipótese de Fechamento:** Todos os outros milhões fora da piscina são assumidos não-relevantes.



INSIGHT EXECUTIVO

Alerta Metodológico de Viés:
O pooling favorece motores participantes. Modelos inéditos que tragam itens relevantes fora do pool original recebem nota zero injustamente!

Limites da Avaliação Offline — Por que a Bancada não basta?

Os Pontos Cegos de Laboratório e a Necessidade de Métricas Vivas

INSIGHT EXECUTIVO

1. Mudez Contextual

Auditores em bancada não possuem o contexto do cliente real:

- Histórico de compras;
- Localização geográfica;
- Urgência e intenção.

INSIGHT EXECUTIVO

2. Cegueira de Vitrine

Métricas de bancada não enxergam a interface:

- Qualidade de fotos;
- Selos de “Frete Grátis”;
- Preço promocional;
- Avaliação do vendedor.

INSIGHT EXECUTIVO

3. Desconexão Operacional

O auditor offline não gasta dinheiro real e ignora:

- Latência de 400 ms;
- Erros de checkout;
- Falta de estoque físico;
- Lentidão do aplicativo.

INSIGHT EXECUTIVO

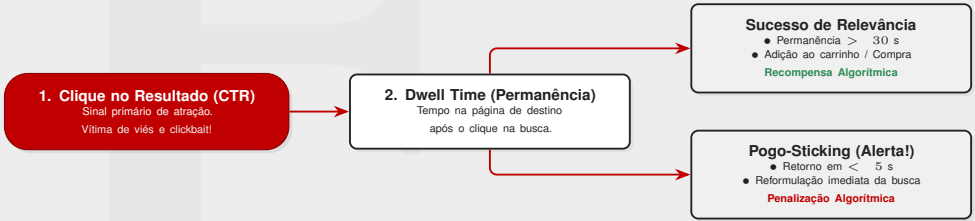
A Regra de Governança Industrial em Grandes Plataformas:
O teste de laboratório (Offline) serve para **eliminar algoritmos desastrosos** sem arriscar a produção.
O teste com usuários reais (Online) decide **quem realmente gera faturamento e lealdade de marca!**

Experimentação Online — Sinais Implícitos e *Dwell Time*

Telemetria Comportamental e Detecção da Real Intenção do Usuário

REFLEXÃO ANALÍTICA & DILEMA DE NEGÓCIO

Como escutar a voz de milhões de clientes simultaneamente sem fazer perguntas diretas? Pela telemetria comportamental implícita de navegação!



INSIGHT EXECUTIVO

A Métricas de Retenção vs. Frustração:

- ***Dwell Time* Longo (> 30 s):** Leitura atenta, consumo do produto ou conversão de venda.
- ***Pogo-Sticking* Rápido (< 5 s):** Frustração imediata, título enganoso (*clickbait*) ou produto indisponível.

Duelo de Algoritmos em Produção — Testes A/B vs. Interleaving

Particionamento de Tráfego versus Pareamento na Mesma Folha de Resultados

INSIGHT EXECUTIVO

1. Teste A/B Tradicional Particionamento de tráfego entre grupos independentes de usuários:

- **Controle (95%):** Recebe o algoritmo atual de produção;
- **Tratamento (5%):** Recebe o modelo novo sob teste.

Limitações Críticas:

- Exige semanas para significância estatística;
- Expõe usuários a modelos instáveis;
- Alto custo de oportunidade se o modelo falhar.

INSIGHT EXECUTIVO

2. Team Draft Interleaving Duelo pareado na **mesma página** de resultados para 100% dos usuários:

- Moeda honesta decide quem escolhe o 1º item;
- Intercala documentos de A e B sem duplicatas;
- Compara cliques recebidos por cada time.

Superpoder do Interleaving:

- Exige até $100\times$ **menos tráfego**;
- Detecta preferência em 24 a 48 horas;
- Risco de experiência reduzido ao mínimo!

Matriz Executiva de Decisão de Métricas por Modelo de Negócio

Guia de Engenharia e Produto para Seleção do Portfólio de Métricas

Tipo de Produto	Comportamento do Usuário	Métrica Offline	Guardrail	Métrica Online (Produção)
E-commerce Marketplace	Navegação ágil, aceita similares, foco no Top-3	$NDCG@5$	$P@1$, Latência	Conversão de Compra, GMV, Queda de *Pogo-Sticking*
Assistente de Voz / IA	Ouve apenas 1 resposta; sem tela de rolagem	MRR / $P@1$	Zero-Result Rate	Abandono de sessão, Pedido de repetição da resposta
LegalTech & Saúde	Investigação profunda de passivos e prontuários	$Recall@K$ / F_2	$P@20$	Taxa de omissão de passivos, Tempo total de pesquisa
Portais Acadêmicos	Pesquisa técnica ampla e bibliográfica	MAP	Curva 11 Pontos	Downloads de PDF, Citações geradas, Artigos salvos
Intranet / FAQs	Busca de procedimentos internos e documentos	MRR	Taxa busca vazia	Redução de tickets abertos no suporte técnico de TI

INSIGHT EXECUTIVO

Diretriz de Arquitetura:
Não existe métrica universal perfeita. O modelo analítico de avaliação deve espelhar com exatidão a função de utilidade econômica e a interface do produto!

O Funil Industrial de Governança de Algoritmos em RI

Pipeline de 4 Etapas Adotado pelas Big Techs para Promoção de Modelos

REFLEXÃO ANALÍTICA & DILEMA DE NEGÓCIO

Fluxo Operacional Padrão: Nenhum algoritmo entra em 100% de produção sem cumprir rigorosamente as 4 etapas do funil de governança!

1. Pesquisa Offline
Bancada Cranfield & TREC
- $NDCG@5$, MAP

Filtro: Elimina ruins

2. Interleaving Online
Duelo Team Draft (24–48h)
- Sensibilidade máxima

Filtro: Detecta preferência

3. Teste A/B Fracionado
Impacto em Negócio (1–2 sem)
- GMV, Conversão, Retenção

Filtro: Confirma receita

4. Rollout Total (100%)
Produção com Telemetria Ativa
- Monitoramento de SLA

Operação Contínua

INSIGHT EXECUTIVO

Checkpoints Cognitivos de Fixação:

1. **Acurácia Proibida:** O quadrante TN domina $> 99,99\%$ da base, camuflando sistemas totalmente inúteis.
2. **Assistente de Voz:** Guiado por MRR e $P@1$, pois a interface acústica só permite vocalizar uma única resposta.
3. **Técnica de Pooling:** Viabiliza benchmarks gigantescos julgando apenas a união dos Top-100 dos competidores.
4. **Vantagem do Interleaving:** Exige até $100\times$ menos tráfego que o A/B e protege a empresa de perdas de faturamento.

Síntese da Aprendizagem e Gancho para a Aula 10 (Sistemas Web)

Do Laboratório às Redes Planetárias: O Salto para a World Wide Web

O Que Consolidamos Hoje:

1. **Camada 1 (Set-based):** Contingência 2×2, P, R, F_β e o paradoxo destrutivo da Acurácia;
2. **Camada 2 (Rankings Binários):** $P@K$, MRR (primeiro acerto), 11 Pontos TREC e a área do MAP;
3. **Camada 3 (Rankings Graduados):** Relevância multifacetada com desconto logarítmico e $NDCG@K$;
4. **Benchmarks & Produção Online:** Amostragem por *Pooling*, *Dwell Time*, Testes A/B e *Team Draft Interleaving*.

INSIGHT EXECUTIVO

A Próxima Fronteira (Aula 10):

*"Tudo o que vimos hoje operou sobre coleções relativamente controladas. Mas o que acontece quando nossa base é a **Web aberta** — caótica, gigantesca, sem catálogo central e cheia de spam?*
*Na próxima aula, construiremos **Web Crawlers** escaláveis e desvendaremos como o **PageRank** utilizou a Teoria dos Grafos para revolucionar a busca planetária!"*